

Альтернативные решения проблемы

	1	2	3	4	5
GROBID / CERMINE	-	-	+	+	-
ABBYY / Tesseract OCR	+	-	+	-	-
Transkribus / Kraken	+	+	+	-	-
Mathpix / Pix2TeX	-	-	-	-	+

1 – OCR текста со сканов и PDF

2 – Поддержка дореформенной орфографии

3 – Анализ структуры страницы и выделение логических блоков

4 – Извлечение метаданных и разделение на статьи

5 – Распознавание математических формул

Существующие решения закрывают задачи частично, но не обеспечивают полный цикл обработки ретродокументов