


# Модуль разделение на статьи



## Эвристический детектор границ статей

Проверка верхних строк страниц:

- не формула
- не тело абзаца
- 5-120 символов
- ≤ 16 слов
- отступы сверху
- заглавный/верхний регистр

→ новая статья

|    |                                            |
|----|--------------------------------------------|
| 1  | [                                          |
| 2  | {                                          |
| 3  | "index": 1,                                |
| 4  | "title": "Дифференциальное уравнен         |
| 5  | "start_page": 1,                           |
| 6  | "end_page": 2                              |
| 7  | },                                         |
| 8  | {                                          |
| 9  | "index": 2,                                |
| 10 | "title": " <u>Beweis der Existenz eine</u> |
| 11 | "start_page": 3,                           |
| 12 | "end_page": 4                              |
| 13 | }                                          |
| 14 | ]                                          |
| 15 |                                            |

Модуль: `extract_document_articles(ocr_text)`

Вход: OCR-текст со страницами, разделёнными \f

Выход: список Article-объектов с index, title, start\_page, end\_page, text, normalized\_text, preview